

RESEARCH PROPOSAL

Confidence-Aware Cross-Stream Attention for Sign Language Translation

Extending SignMusketeers with Reliability-Aware Multi-Stream Fusion

Target Venue: ACL / EMNLP Findings 2025-2026

Base Paper: SignMusketeers (ACL 2025)

1. Overview & Motivation

1.1 Paper gốc: SignMusketeers

SignMusketeers (Gueuwou et al., ACL 2025) là một phương pháp hiệu quả về mặt tính toán cho bài toán dịch ngôn ngữ ký hiệu (Sign Language Translation - SLT). Paper đề xuất một kiến trúc đa luồng (multi-stream) gồm 4 kênh thông tin:

- Face stream: DINOv2-F encoder học biểu hiện khuôn mặt
- Left hand stream: DINOv2-H encoder học hình dạng bàn tay trái
- Right hand stream: DINOv2-H encoder học hình dạng bàn tay phải
- Body pose stream: MediaPipe coordinates chuyển hóa

Kết quả: đạt BLEU 14.3 trên How2Sign với chỉ 3% compute so với SSVP-SLT (SOTA trước đó), sử dụng 41x ít dữ liệu pre-training hơn và 160x ít iterations hơn.

1.2 Gap quan trọng chưa được giải quyết

Dù đạt kết quả ấn tượng về hiệu quả tính toán, SignMusketeers có 3 điểm yếu cơ bản trong cách fusion 4 streams:

Van de	Hien trang trong SignMusketeers	Tac dong
No stream interaction	4 streams chỉ được concat + linear project	Mất dependency giữa các kênh ngôn ngữ
Equal reliability	Mọi stream được xử lý như nhau bất kể chất lượng detection	Noise từ bad detection được truyền thẳng vào T5
Static fusion	Cùng một fusion function cho mọi frame	Không adapt khi tay bị che, mất quay nghiêng

1.3 Linguistic Insight - Motivation chính

Trong ngôn ngữ ký hiệu, ý nghĩa không nằm trong từng stream riêng lẻ mà nằm trong sự KẾT HỢP giữa các streams. Ví dụ cụ thể:

Tay ở vị trí X + mặt bình thường	= statement (câu kể)
Tay ở vị trí X + mày nhui	= yes/no question
Tay ở vị trí X + miêng mồm	= rhetorical question

Linear projection sau khi concat không thể capture được mọi quan hệ này. Đây là gap thực sự và chính xác mà CA-CSA giải quyết.

2. Proposed Method: CA-CSA

CA-CSA (Confidence-Aware Cross-Stream Attention) là kiến trúc thay thế bước fusion trong SignMusketeers Phase 2. Toàn bộ encoder (DINOv2-F, DINOv2-H) giữ nguyên - chỉ thay đổi cách 4 streams được kết hợp.

2.1 Pipeline Tổng thể

```
SignMusketeers gốc:
```

```
Frame t --> [concat: face|lhand|rhand|pose] --> Linear(1166->768) --> T5
```

```
Proposed CA-CSA:
```

```
Frame t --> Stream Tokenization
          --> Confidence Score Extraction
          --> Confidence Bias Matrix
          --> Cross-Stream Attention (x2 layers)
          --> Confidence-Weighted Pooling
          --> Linear(d->768) --> T5
```

2.2 Bước 1: Stream Tokenization

Tại sao cần bước này?

Khi concat 4 streams rồi project qua 1 linear layer, identity của từng stream bị mất. Model không biết dimension nào thuộc về tay, dimension nào thuộc về mặt. Linear layer chỉ học một phép biến đổi toàn cục vô nghĩa về mặt ngữ nghĩa.

Cách làm:

Project mỗi stream về cùng dimension $d=256$ qua stream-specific linear layers:

```
s_face  = Linear_face(f_face)    # f_face in  $\mathbb{R}^{384}$  --> s_face in  $\mathbb{R}^{256}$ 
s_lhand = Linear_lhand(f_lhand)  # f_lhand in  $\mathbb{R}^{384}$  --> s_lhand in  $\mathbb{R}^{256}$ 
s_rhand = Linear_rhand(f_rhand)  # f_rhand in  $\mathbb{R}^{384}$  --> s_rhand in  $\mathbb{R}^{256}$ 
s_pose  = Linear_pose(f_pose)    # f_pose in  $\mathbb{R}^{14}$    --> s_pose in  $\mathbb{R}^{256}$ 
```

Thêm Stream Identity Embedding để model biết vai trò ngôn ngữ học của từng stream (tương tự positional embedding trong Transformer):

```
s_i = s_i + E_stream[i]  # E_stream: learned embedding 4x256
```

Dòng gộp:

Tao dieu kien tien quyet de cac streams co the interact co y nghia voi nhau. Face stream mang thông tin grammatical (yes/no, negation), hand stream mang thông tin lexical - model can biet su khác biệt này.

2.3 Buoc 2: Confidence Score Extraction

Tai sao can buoc nay?

Khi tay bị che, mặt quay nghiêng, hoặc ảnh sáng xấu, detector trả về kết quả không chính xác. SignMusketters xử lý bằng cách lấy frame trước đó (heuristic). Sau đó T5 nhận noise như thể là signal thật - đây là nguyên nhân giảm chất lượng dịch.

Hai nguồn confidence:

Nguồn	Mô tả	Hạn chế
MediaPipe confidence	Score có sẵn từ detector (0-1)	Không được train cho sign language, kém tin cậy
Learned confidence	MLP nhỏ predict reliability từ feature	Can train them nhưng chính xác hơn nhiều

Learned Confidence Module (đóng góp chính):

```
class LearnedConfidence(nn.Module):
    def __init__(self):
        self.scorer = nn.Sequential(
            nn.Linear(256, 64),
            nn.ReLU(),
            nn.Linear(64, 1),
            nn.Sigmoid()
        )
    def forward(self, stream_token, mediapipe_conf):
        learned = self.scorer(stream_token)
        return alpha * learned + (1-alpha) * mediapipe_conf
```

Learned confidence được train end-to-end với translation objective - nó học được sign-specific unreliability patterns mà MediaPipe bỏ qua.

Temporal Smoothing (optional but important):

Confidence không nên nhìn từng frame riêng lẻ. Nếu hand confidence thấp ở nhiều frames liên tiếp = occlusion thực sự, cần compensate mạnh. Nếu chỉ 1 frame = detection noise, chỉ cần compensate nhẹ.

```
c_smooth[t] = GRU(c[t-k:t]) # k=5, lightweight 1-layer GRU
```

2.4 Bước 3: Confidence Bias Matrix - Core Contribution

Tại sao đây là đóng góp chính?

Confidence không chỉ là post-hoc filter hay simple weighting. Nó trở thành một phần của attention mechanism - mô hình học cách sử dụng confidence information để redistribute attention một cách adaptive.

Cách xây dựng:

Với 4 streams, attention matrix có shape 4x4. Confidence bias:

```
B[i,j] = log(c_j + epsilon)
```

Ý nghĩa: stream i khi attend đến stream j,
bi bias bởi confidence của stream j.

Attention có bias:

```
Attention(Q,K,V,B) = softmax((QK^T / sqrt(d)) + B) * V
```

Ví dụ trực quan:

```
c_lhand = 0.9 (hand detection tốt):  
B[:, lhand] = log(0.9) = -0.1 --> gần như không ảnh hưởng  
--> các streams khác attend bình thường đến lhand
```

```
c_lhand = 0.1 (hand detection kém):  
B[:, lhand] = log(0.1) = -2.3 --> penalty lớn  
--> attention weight đến lhand giảm mạnh  
--> mô hình tự động shift attention sang face và pose
```

Tại sao dùng log scale:

- Log scale phù hợp với softmax - tạo soft gating thay vì hard threshold
- Giữ gradient flow ngay cả khi confidence thấp - mô hình vẫn học được
- Precedent trong literature: ALiBi positional encoding dùng cùng cơ chế này

2.5 Buoc 4: Cross-Stream Transformer Block

Tai sao can cross-attention giua cac streams?

Face token can biet tay dang lam gi truoc khi duoc fuse. Hand token can biet mat dang express gi. Linear projection sau concat khong the capture nhung moi quan he nay.

Kien truc:

```
def CA_CSA_block(S_t, confidence_scores):
    # S_t: (4, 256) - 4 stream tokens
    # confidence_scores: (4,)

    B = build_confidence_bias(confidence_scores) # (4, 4)

    Q = S_t @ W_Q # (4, 256)
    K = S_t @ W_K
    V = S_t @ W_V

    attn = softmax((Q @ K.T / sqrt(256)) + B)
    attended = attn @ V

    S_t = LayerNorm(S_t + attended) # residual
    S_t = LayerNorm(S_t + FFN(S_t))
    return S_t # (4, 256)
```

Stack 2 layers CA-CSA block - du de moi stream attend den moi stream khac, khong qua heavy, tranh overfitting. Compute them rat nho: 4 tokens x 2 layers.

2.6 Buoc 5: Confidence-Weighted Pooling

Tai sao khong dung mean pooling?

Mean pooling treat 4 streams nhu nhau. Mot stream co confidence 0.1 van contribute bang stream co confidence 0.9. Day la diem yeu ro rang.

Confidence-weighted pooling:

```
w = softmax([c_face, c_lhand, c_rhand, c_pose])
f_fused = sum(w_i * s_i) # in R^256
f_final = Linear(f_fused) # R^256 --> R^768 cho T5
```

Day la second level cua confidence awareness: lan dau o attention (how streams interact), lan hai o pooling (how streams contribute to output). Tao ra pipeline confidence-aware end-to-end.

3. Experiment Design

3.1 Datasets

Dataset	Su dung	Size	Ghi chu
YouTube-ASL	Pre-training (phase 1)	~700 hours	Giu nguyen nhu paper goc
How2Sign	Supervised training + eval	31k/1.7k/2.3k clips	Main benchmark
YouTube-ASL	Zero-shot eval (YT schedule)	Test split	Consistency voi paper goc

3.2 Training Schedules

Giu nguyen 3 schedules cua paper goc de co the so sanh truc tiep:

- H2S: Supervised training chi tren How2Sign
- YT: Supervised training tren YouTube-ASL, eval zero-shot tren How2Sign
- YT->H2S: Train tren YouTube-ASL, fine-tune tren How2Sign (best setting)

3.3 Ablation Studies - Quan trong nhât

Day la phan chung minh contribution cua tung component. Can thiet ke sao cho moi dong isolate chinh xac 1 thay doi:

Model	Cross-Attn	Conf Bias	Learned Conf	BLEU
Baseline (SignMusketeers)	x	x	x	14.3
+ Cross-stream attention only	O	x	x	?
+ Confidence bias (MediaPipe)	O	O (MP)	x	?
+ Confidence bias (Learned)	O	O (L)	O	?
+ Temporal smoothing	O	O (L+T)	O	?
Full CA-CSA	O	O (all)	O	Target

Moi row prove mot dieu:

- Row 2: Stream interaction giup ich (khong can confidence)

- Row 3 vs 4: Learned confidence tot hon MediaPipe confidence
- Row 4 vs 5: Temporal modeling giup khi co occlusion dai
- Row 5 vs 6: End-to-end training tot hon

3.4 Analysis Experiments - De paper sau hon

Attention Visualization:

Visualize attention weights theo thoi gian de chung minh model hoc dung behavior:

- Khi hand bi che -> attention tu face/pose den hand giam ro rang
- Khi co grammatical marker (yes/no question) -> face stream duoc attend nhieu hon
- Tao ra qualitative evidence manh cho reviewers

Confidence Calibration Analysis:

- So sanh MediaPipe confidence vs Learned confidence
- Khi nao learned tot hon? (sign-specific handshapes, occlusion)
- Khi nao MediaPipe du? (clear video, good lighting)

Robustness Under Occlusion:

- Tao synthetic occlusion test set: che tay/mat o nhieu muc do khac nhau
- So sanh CA-CSA vs baseline duoi dieu kien nay
- Ket qua du kien: CA-CSA robust hon dang ke khi occlusion > 30%

Stream Contribution Analysis:

- Extend Table 4 cua paper goc voi CA-CSA
- Show rang voi CA-CSA, individual stream performance tang vi co context

3.5 Baseline Comparisons

Method	Ly do so sanh
SignMusketeers (paper goc)	Direct baseline - phai beat
Uthus et al. 2023 (pose-based)	Show rang CA-CSA hon pose-only
SSVP-SLT (Rust et al. 2024)	SOTA reference - gap nen giam
Simple confidence gating	Ablation: thay vi bias, dung hard threshold

4. Implementation Plan

4.1 Timeline Chi Tiet

Tuan	Phase	Tasks cu the	Milestone
1-2	Setup	Reproduce baseline 14.3 BLEU, setup eval pipeline, verify data preprocessing	Baseline verified
3	Core impl	Stream tokenization + identity embedding, confidence bias matrix	First integration
4	Core impl	Cross-stream attention block (2 layers), confidence-weighted pooling	CA-CSA v1 done
5	Learned conf	LearnedConfidence module, temporal GRU smoothing, end-to-end training setup	Full pipeline
6-7	Training	First training runs, debug attention weights, hyperparameter search	First results
8-9	Ablations	Chay 5 ablation configurations, moi config 1-2 ngay, multiple seeds	Ablation table
10	Analysis	Attention visualization, occlusion experiments, confidence calibration	Analysis done
11-12	Writing	Draft paper, method section, experiment section	Draft v1
13-14	Revision	Feedback, revision, polish, final submission	Submission ready

4.2 Compute Requirements

Component	Compute	Ghi chu
Reproduce baseline	~880 GPU-hours	Theo paper goc
CA-CSA overhead	~2-3% extra	Chi 4 tokens x 2 layers

Ablation studies (5 runs)	~4400 GPU-hours	5 x 880
Analysis experiments	~500 GPU-hours	Occlusion, visualization
Total estimated	~6000 GPU-hours	< 1/5 của SSVp-SLT

4.3 Key Implementation Details

Numerical stability:

- $\epsilon = 1e-6$ trong $\log(c + \epsilon)$ để tránh $\log(0)$
- Clip confidence scores vào $[0.05, 0.95]$ trước khi tính bias
- Monitor gradient flow qua confidence bias layer

Hyperparameters can tune:

- $d = \{128, 256, 384\}$ - stream token dimension
- $\text{num_heads} = \{2, 4, 8\}$ - attention heads
- $\text{num_layers} = \{1, 2, 3\}$ - CA-CSA layers
- $\alpha = \{0.3, 0.5, 0.7\}$ - blend ratio learned vs MediaPipe confidence
- $k = \{3, 5, 7\}$ - temporal smoothing window

Điểm cần debug đặc biệt:

- Attention weights có phản ánh đúng confidence không? (visualize som)
- Learned confidence có học được signal có ý nghĩa không? (monitor training)
- Gradient vào LearnedConfidence module có ổn định không?

5. Summary of Contributions

5.1 Technical Contributions

Contribution	Mô tả	Novelty
CA-CSA Architecture	Confidence-aware cross-stream attention thay the linear fusion	Chưa có trong SLT literature
Learned Confidence	Sign-specific reliability estimator train end-to-end	Giải quyết limitation MediaPipe mà paper gốc nêu
Temporal Confidence	GRU smoothing phân biệt occlusion vs noise	Novel trong multimodal fusion
E2E Confidence Pipeline	Confidence được dùng từ attention đến pooling	Systematic, không phải point solution

5.2 Scientific Contributions

- Chứng minh rằng reliability-aware stream interaction là missing inductive bias trong toàn bộ multi-stream SLT literature
- Systematic study về khi nào MediaPipe confidence đủ tin cậy và khi nào cần learned confidence
- Occlusion robustness benchmark có thể được community sử dụng lại
- Attention visualization cho thấy correlation với linguistic structure của sign language

5.3 Narrative cho Paper

Core Claim	Các design choices trong multi-stream SLT phải được driven by linguistics của sign language, đặc biệt là reliability của từng channel. CA-CSA hiện thực hóa nguyên tắc này qua confidence-aware fusion.
Key Result	CA-CSA đạt BLEU XX.X trên How2Sign YT->H2S, cải thiện +Y.Y BLEU so với SignMusketeers baseline (14.3), trong khi giữ compute overhead < 5%.
Target Venue	ACL / EMNLP Findings 2025-2026, tương đương với paper gốc SignMusketeers.

5.4 Đánh giá Rủi ro

Rủi ro	Xác suất	Giải pháp
--------	----------	-----------

Gain BLEU qua nho (<0.5)	Trung binh	Tap trung vao robustness analysis; frame la analysis paper
Learned confidence khong hoi tu	Thap	Fall back sang MediaPipe + simple bias
Reviewer hoi 'qua don gian'	Cao	Depth of analysis > complexity of method
Reproduce baseline that bai	Thap	Contact authors; dung checkpoint neu co

6. Expected Results & Paper Structure

6.1 Expected BLEU Improvements

Model	Schedule	BLEU (expected)	So voi baseline
SignMusketeers baseline	H2S	2.4	-
CA-CSA (ours)	H2S	3.0-3.5	+0.6 to +1.1
SignMusketeers baseline	YT->H2S	14.3	-
CA-CSA (ours)	YT->H2S	15.0-15.5	+0.7 to +1.2
SSVP-SLT (SOTA)	YT->H2S	14.7	Reference

Voi CA-CSA, ky vong dat hoac vuot qua SSVP-SLT (14.7) trong khi van giu compute hieu qua cua SignMusketeers. Day la compelling result.

6.2 Paper Structure De xuất

1. Abstract: CA-CSA, key results, efficiency
2. Introduction: Gap trong multi-stream SLT, motivation tu linguistics
3. Related Work: Multi-stream SLT, confidence-aware methods, multimodal fusion
4. Method: CA-CSA - tokenization, confidence extraction, bias attention, pooling
5. Experiments: Main results, ablations, analysis
6. Discussion: Khi nao CA-CSA giup nhat, linguistic interpretation
7. Conclusion & Future Work

6.3 Figures Can Co

- Figure 1: Architecture diagram - so sanh pipeline goc vs CA-CSA
- Figure 2: Confidence bias matrix visualization - direct example
- Figure 3: Attention weight heatmap theo thoi gian - qualitative evidence
- Figure 4: BLEU vs compute plot (extend Figure 2 cua paper goc)
- Figure 5: Robustness under occlusion curves